

ALFABETIZA BRASIL • DATA PLATFORM • GCP

Como transformar milhões de registros educacionais em decisões confiáveis sobre alfabetização?

Pipeline híbrida em GCP com Arquitetura Medalhão, qualidade de dados, FinOps e análise territorial.

3,87 mi

registros de alunos ingeridos

5.352

municípios analisados em 2024

3


quality gates aprovados

3,35 mi

registros preparados para ML


0 problema não era falta de dado

Era transformar fontes públicas heterogêneas em uma base confiável para decisão.



Uma pipeline híbrida com camadas de confiança

Batch para o histórico, streaming simulado para eventos e Medalhão para governança.




Isolamento os eventos simulados ficam separados dos dados públicos oficiais para não misturar registros sintéticos com dados reais.

PRÓXIMO PASSO Pub/Sub → Cloud Run · Functions · Dataflow → Bronze de eventos

A pipeline só avança quando passa pelos gates

Qualidade, rastreabilidade e custo tratados como requisitos da arquitetura.



De dados brutos a estruturas analíticas

O projeto não parou na ingestão: entregou camadas, evidências e base preparada para análise.

7

tabelas

camada Bronze

7

tabelas

camada Silver

6

tabelas + 1 view

camada Gold

3,87

mi

registros de alunos

3.354.661

registros elegíveis para ML

~85s

execução end-to-end

~1GB

processado

Tempos e volumes referem-se à **execução observada**— não a um SLA de produção.

EVIDÊNCIAS ENTREGUES

- Notebooks
- SQLs
- Logs
- Quality gates
- Manifestos
- Gráficos
- Tabelas analíticas
- Documentação técnica
- Git · branches & PRs


Os dados revelaram uma desigualdade territorial relevante

53,29%
atingiram a meta

46,71%
não atingiram

Cumprimento da meta por região · 2024

% de municípios que atingiram a meta



Sul: menor resultado regional — meta média alta (72,31%) e resultado médio 64,68%.

Evolução 2023 → 2024 × cumprimento da meta

municípios comparáveis, por grupo



58,51% avançaram entre 2023 e 2024 · estável: 14 municípios (0,27%).

11,28 p.p. gap médio nacional (não atingentes)

15,57 p.p. gap médio no Sul (não atingentes)

Leitura de associação e diagnóstico — não afirma causalidade.

Priorização hoje, inteligência preditiva amanhã

Municípios prioritários • maior gap

gap vs. meta (p.p.)



9 de 10 no Rio Grande do Sul

recuo + meta não atingida

VARIÁVEL-ALVO target_alfabetizado

Classificação oficial do aluno quanto à alfabetização — disponível após a aplicação e o processamento da avaliação.

REMOVIDO PARA EVITAR DATA LEAKAGE

Proficiência

Classificação pelo corte de 743

Indicador de coerência

Identificadores mantidos apenas para rastreabilidade — nunca como features.

BASE PREPARADA • 3.354.661 REGISTROS

Treino 69,97%

Val. 15,00%

Teste 15,03%

2.347.122

503.191

504.348

HONESTIDADE TÉCNICA A infraestrutura e a base estão prontas para um modelo futuro — **ainda não existe performance preditiva medida.**

Uma plataforma auditável para decisões educacionais

VALOR

- Priorização territorial baseada em evidências
- Comparação entre metas e resultados
- Análise temporal e regional
- Rastreabilidade da pipeline
- Base confiável para políticas públicas
- Preparação responsável para IA

LIMITAÇÕES HONESTAS

- Streaming simulado e isolado
- Colab não opera continuamente
- Sem orquestrador gerenciado
- Correlação não implica causalidade
- Médias regionais simples, não ponderadas
- Nenhum modelo treinado nem métrica preditiva
- Arquitetura acadêmica exige adaptação

PRÓXIMOS PASSOS

- Pub/Sub para ingestão de eventos
- Cloud Run, Functions ou Dataflow
- Cloud Logging e alertas
- Cargas incrementais
- Fontes socioeconômicas externas
- Modelo preditivo com métricas reais
- Dashboard executivo

Sandbox acadêmico → Produção GCP → IA educacional